

Taller B4-T1

Diseño de Redes Confiables

Justicia e incertidumbre en clasificación de riesgo de crédito

1

Capa Custom

Ratio de
endeudamiento

2

FAIR Loss

Penalización por
género

3

AutoML

Keras Tuner

4

Incertidumbre

Error + MC Dropout

Equipo: Albert Martin · Josep Pérez Segura · Rodolfo Villena

CONTEXTO

Objetivo y datos

Dataset

Home Credit Default Risk
307k solicitudes · 122 variables

Target

TARGET = 1 → Dificultad de pago
TARGET = 0 → Buen pagador

Variable sensible

CODE_GENDER
No entra como predictor directo

Objetivo


- Predecir riesgo de impago
- Reducir dependencia respecto al género
- Reportar confianza/incertidumbre

ARQUITECTURA

Punto 1 · Arquitectura customizada

DebtBurdenLayer

- Calcula ratios financieros
- Usa importes sin escalar
- Saturación suave con una tangente hiperbólica (tanh)



FAIR LEARNING


Punto 2 · Aprendizaje justo

Loss customizada

$BCE + \lambda \cdot \text{dependencia}$
Pearson² y CKA RBF

- `CODE\_GENDER` no entra al modelo
- Se usa para penalizar dependencia
- λ controla el trade-off

Mejor FAIR
CKA RBF · $\lambda = 10$



La curva muestra el coste de reducir dependencia sensible.

OPTIMIZACIÓN

Punto 3 · AutoML con Keras Tuner


$$val_combined = val_auc - w_{sel} \cdot CKA_RBF(\hat{y}, s)$$

Hyperband explora

- Número de capas
- Unidades por capa
- Dropout
- Learning rate
- λ de fairness


Mejor configuración

1 capa · 16 unidades · $\lambda=1$
Lr=0.0099 · 0 Dropout



OPTIMIZACIÓN


Punto 3 · AutoML con Keras Tuner



RESULTADOS

Comparativa de modelos

Rendimiento vs dependencia sensible



Base

AUC 0.737 · CKA 0.0110

FAIR pre-tuner

AUC 0.728 · CKA 0.0003

FAIR tuneado

AUC 0.733 · CKA 0.0028

INCERTIDUMBRE

Punto 4 · Incertidumbre predictiva

Dos estimadores

Modelo auxiliar

Predice $|\hat{y} - y|$
como error esperado

MC Dropout

PRE = Útil
POST = dropout ≈ 0


Salida final

Clase + Prob. + Error
Estimado


INCERTIDUMBRE







Punto 4 · Incertidumbre predictiva

Curvas de entrenamiento — incertidumbre pre-tuner



Curvas de entrenamiento — incertidumbre post-tuner





CIERRE

Conclusiones

Capa custom

FAIR Loss

Keras Tuner

Incertidumbre

Restricción matemática

Ratios financieros explícitos y controlados con tanh.

Incertidumbre

Cada predicción se acompaña de una señal de confianza.

Justicia

La FAIR Loss reduce la dependencia respecto a CODE_GENDER.

Mensaje final

Integrando el Machine Learning, el Fair Learning, el AutoML y el estudio de la incertidumbre, no solo creamos un sistema de concesión de crédito: creamos un modelo capaz de predecir el riesgo, reducir sesgos, optimizar sus decisiones y reconocer cuándo no es fiable.

Ese equilibrio es lo que convierte una red neuronal en una herramienta defendible en un entorno real.