

TALLER: B4-T1

Diseño de Redes Confiables (Justicia e Incertidumbre)

Datos básicos:

- Grupos de 3 estudiantes.
- Entrega el día 25 junio a través del aula virtual a las 18:00.
- El entregable es un repositorio de GitHub y un documento en formato PDF.
- El día 25 hará una presentación cada grupo de 5 minutos.

1. Objetivo de la práctica

Diseñar, entrenar y auditar un modelo de clasificación neuronal para la concesión de créditos asegurando que sus decisiones sean precisas, justas (Fair Learning) y honestas respecto a su nivel de confianza (Incertidumbre). Se desarrollarán modelos que integren restricciones físicas/matemáticas mediante capas customizadas, que penalicen sesgos demográficos mediante funciones de coste customizadas, y que cuantifiquen la varianza de su predicción.

2. Contexto del problema

La práctica se desarrolla en forma de taller semi-guiado, estructurado en dos sesiones prácticas de 2,5 horas cada una:

Construcción y Optimización (Sesión 1): Planteamiento del problema, implementación de la arquitectura base y búsqueda de hiperparámetros con Keras Tuner.

Incertidumbre y Auditoría (Sesión autónoma): Implementación de la parte de aprendizaje justo e inferencia para estimar la incertidumbre y análisis de robustez.

Exposición de las soluciones (Sesión 2): Presentación y defensa técnica de los resultados, 5 minutos mas preguntas.

La tarea se entregará justo antes de la sesión 2.

3. Datos disponibles

Se utilizará el dataset “Home Credit Default Risk”:

<https://www.kaggle.com/competitions/home-credit-default-risk/overview>

El dataset está centrado en la predicción financiera de perfiles con poco historial crediticio. Se proporciona un notebook esqueleto para la lectura y preprocesado inicial de datos:

Lectura_datos_Taller_Fairness.ipynb

Estas serán las variables:

- Variable Objetivo: Clasificación binaria (TARGET, 1: Dificultades de pago, 0: Pagó a tiempo).
- Variable Sensible: Género del solicitante (CODE_GENDER). El modelo no debe discriminar basándose en esta característica.
- Variables de Entrada: Ingresos, anualidades, y puntuaciones de fuentes externas (EXT_SOURCE_1, 2, 3). Estas últimas contienen valores ausentes imputados que serán clave para estudiar la incertidumbre del modelo.

4. Tarea del estudiante

El estudiante tiene cuatro tareas principales:

1. **Arquitectura Customizada:** Implementar una capa customizada. Por ejemplo, una capa que calcule internamente el "Ratio de Endeudamiento" (combinando variables financieras de entrada) y aplique una saturación o restricción matemática sobre este ratio antes de pasarlo a las capas densas.
2. **Aprendizaje Justo (FAIR Loss):** Diseñar una función de coste customizada que combine el error de clasificación con una penalización por dependencia estadística entre la variable predicha y la variable sensible.
3. **AutoML:** Utilizar *Keras Tuner* para encontrar la topología óptima de la red.
4. **Incertidumbre:** Modificar el modelo para que la predicción sobre el conjunto de test devuelva tanto la clase predicha como la varianza/incertidumbre de la misma.

5. Entregables

Se deberá entregar un github con los modelos y los resultados, y una presentación (report en pdf) a través del aula virtual.

Contenido obligatorio del GitHub:

- El código de entrenamiento, optimización y evaluación de cada modelo. El código debe generar todas las gráficas y tablas reportadas.
- Un gráfico de dispersión (scatter plot) o Curva de Pareto que muestre el trade-off obtenido por Keras Tuner: Precisión (Eje Y) vs. Medida de Dependencia FAIR (Eje X) para los distintos valores de fairness.
- Un gráfico de distribución de la incertidumbre (varianza de las predicciones) comparando a los usuarios clasificados como "Buen pagador" vs "Mal pagador".
- Para cada entrenamiento final, incluir las curvas de loss donde se vea que el modelo ha convergido.

- Una tabla que resuma los resultados del modelo Base (sin restricciones FAIR) frente al mejor modelo FAIR en el conjunto de test. Remarcar el valor del mejor modelo en test.

Contenido de la presentación:

- Explicación de la restricción matemática introducida en la Capa Custom y la métrica de dependencia seleccionada para la Loss.
- Análisis de la gráfica de Pareto: ¿Cuánto se sacrifica en rendimiento predictivo por conseguir un modelo justo?
- Reflexión sobre la incertidumbre: ¿El modelo muestra mayor incertidumbre en perfiles donde la calidad de las fuentes externas (EXT_SOURCE) es peor?

6. Criterios de evaluación

- (30 %) Github
- (70 %) Presentación. Se presentará el pdf entregado en el aula virtual. Cada grupo hará una presentación corta (5 minutos) explicando sus resultados.